Extraction Automatique de Réseaux de Personnages

De la Présence à la Polarité

Steve **SANOGO**
Master 1 en Intelligence Artificielle

Malika **GHILAS**
Master 1 ILSEN

10 mars 2026

AVIGNON UNIVERSITÉ

Objectifs du Projet

Extraction Structurelle

- Reconnaissance d'Entités Nommées
- Résolution d'Alias
- Graphe de Cooccurrences

Enrichissement Sémantique

- Détection d'interactions
- Polarité des relations
- Analyse narrative

Analyse du Graphe Final

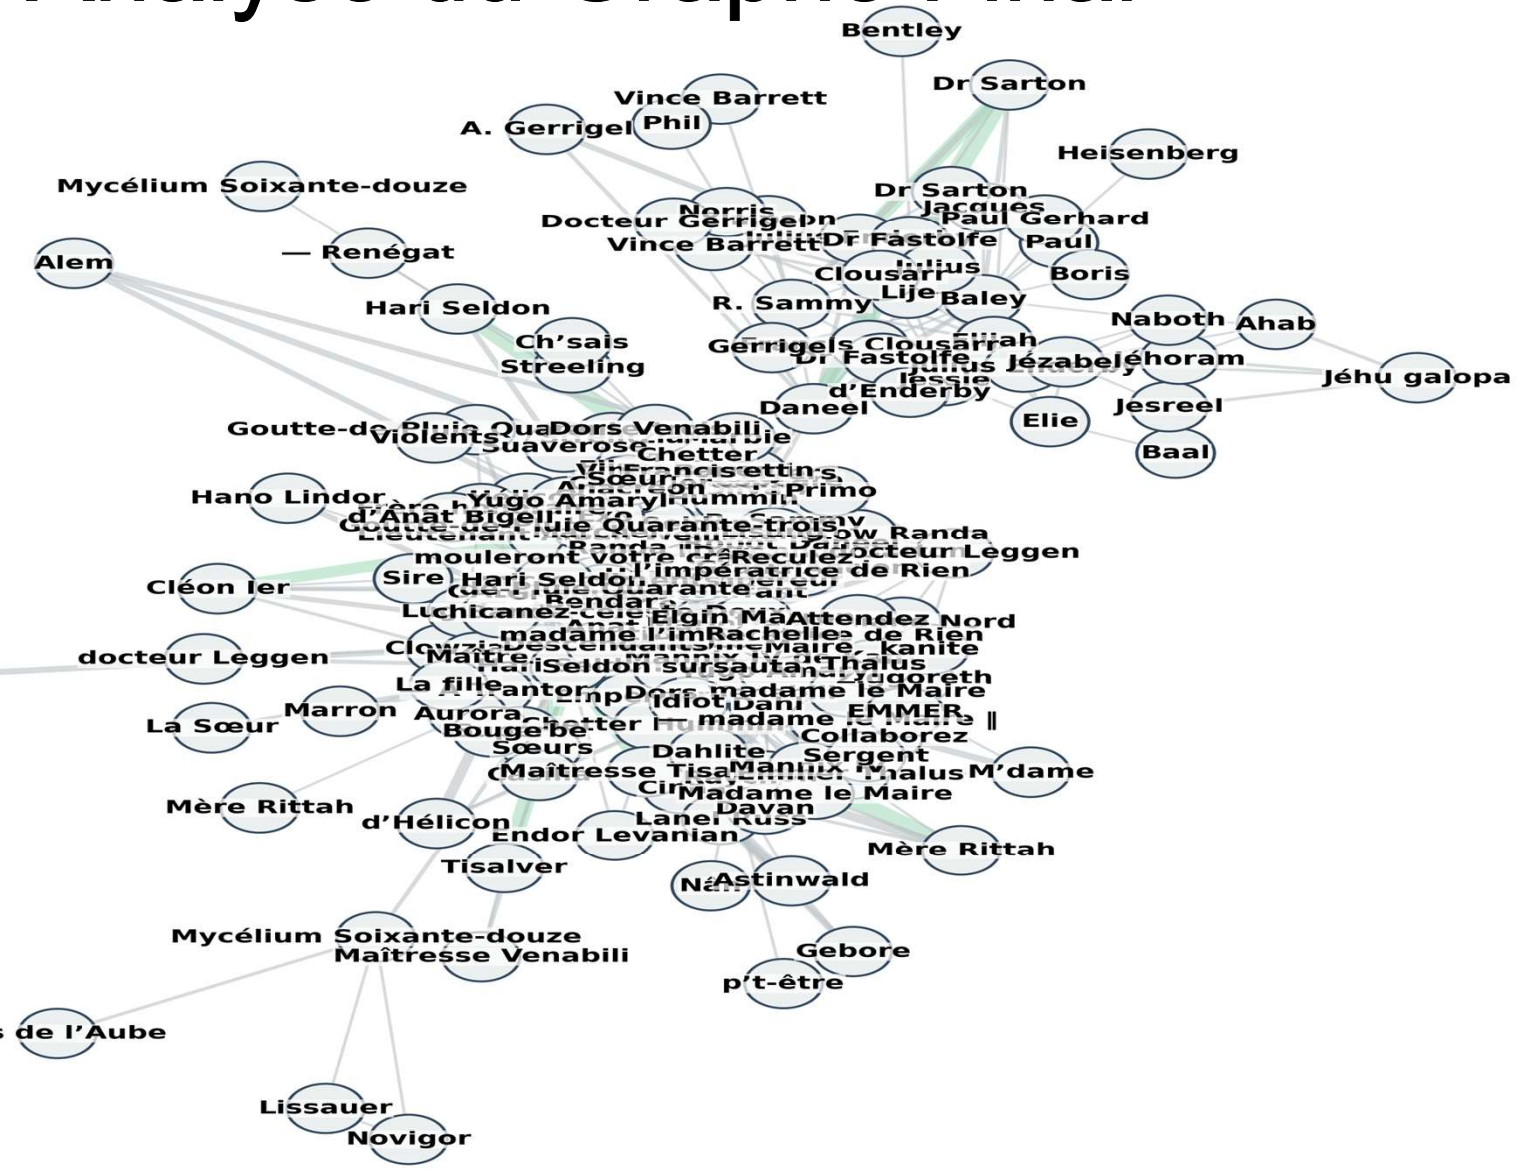

~350

Nœuds

~147

Nœuds distincts

Richesse du graphe

Autres Statistiques

- Hari Seldon : hub central (degré 51)
- Degré moyen ≈ 4,5

Zoom : Dors Venabili

Personnage secondaire : Dors Venabili est connectée à toutes les communautés de la fuite et lie des relations d'amitié et de confiance avec la plupart des personnages rencontrés, dont la plus forte avec Hari Seldon : une protection permanente, progressivement teintée d'affection mutuelle.

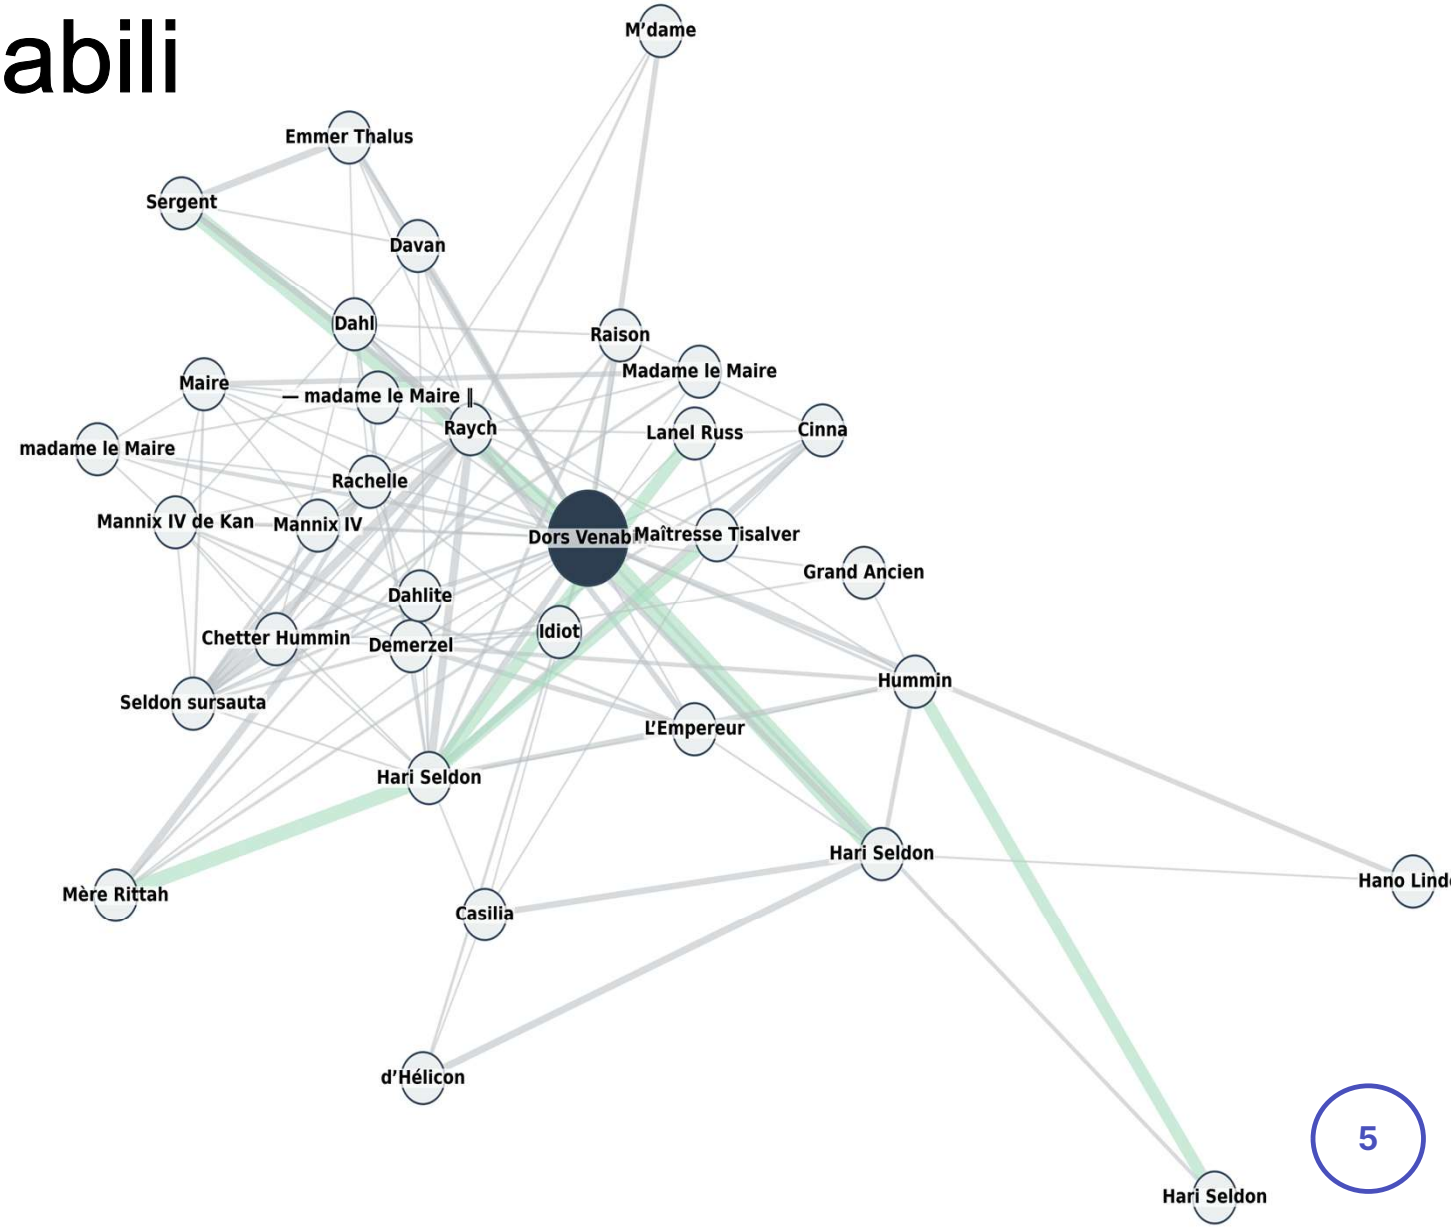

Évolution des Performances

Évolution du score F1 : S2

0,57

SCORE F1 ACTUEL

Objectif : ≥ 0,6

Axe 1 : NER/Alias | Axe 2 : Polarité

Nouvelle architecture du système

Pipeline initial

Corpus → Preprocessor → NER → Alias Resolution → Graph Builder

Extension : Polarity

4 nouveaux modules :

- resource_manager.py
- polarity_analyzer.py
- extraction_rules.py
- Graph Enrichment

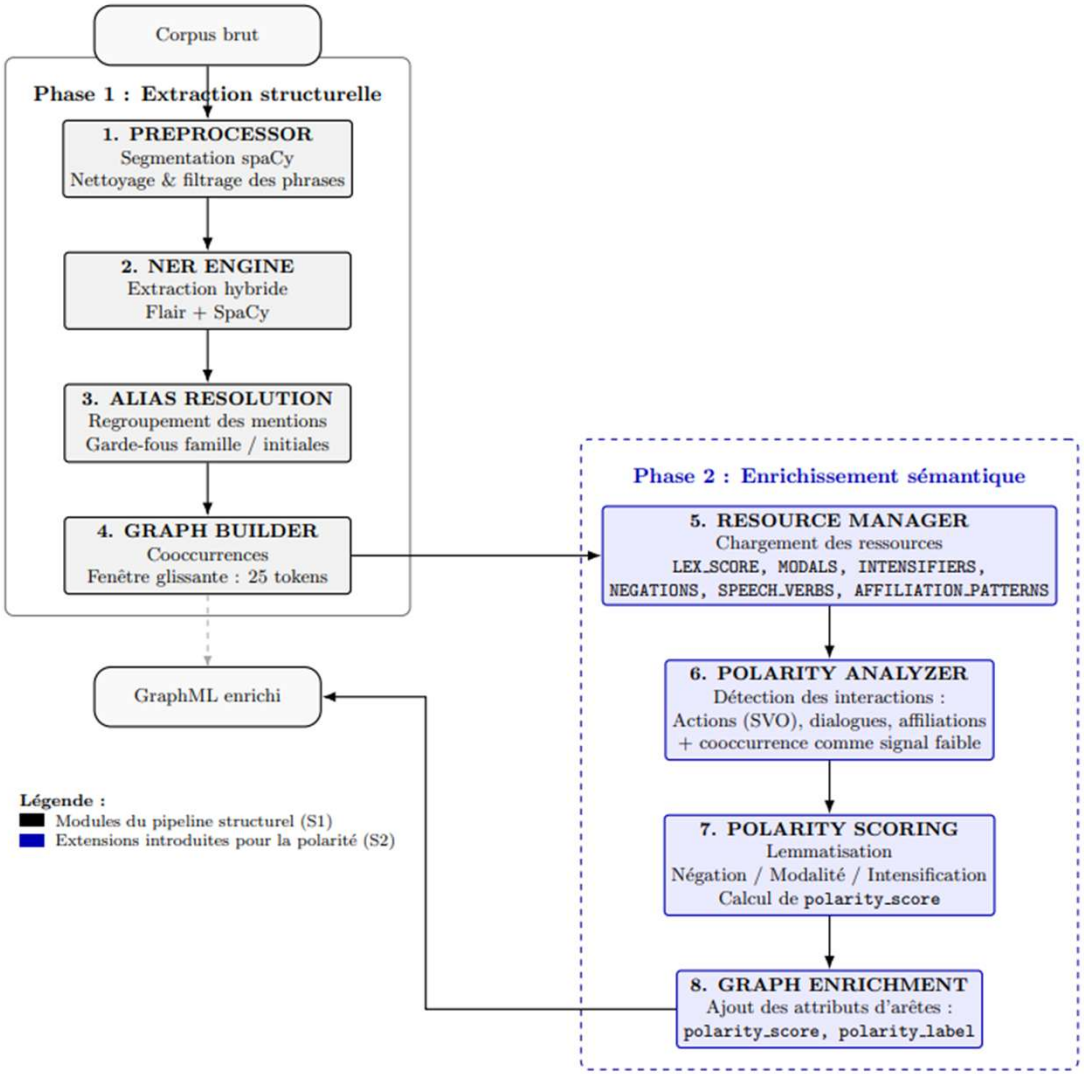

Optimisation NER

Modèle Hybride

SpaCy + Flair combinés pour un rappel maximal.

Ensemble de règles

- Blacklist étendue (lieux et concepts SF).
- Préservation spécifique des robots (**R. Daneel**).

Pas de LLM

Évité en raison du coût et de la reproductibilité.

Score de Polarité

Le Score de polarité entre deux entités A et B au sein d'un même chapitre est donné par :

$$S_c(A,B) = \sum_{\text{actions}} s_e + \beta \sum_{\text{dialogues}} s_e + \delta \sum_{\text{affiliations}} s_e + \varepsilon \cdot f(\text{cooc})$$

Actions > **Dialogues** > **Affiliations** > **Cooccurrence**

S_e étant le score local d'un événement entre A et B

β = 1.2 (Dialogues)

δ = 2.0 (Affiliations)

ε = 0.05 (signal faible de cooc.)

$$\mathrm{Sc}(A, B) = \begin{cases} \textit{Ami} & \textit{si } S > 1.5 \\ \pm\,\textit{Ami} & \textit{si } 0.5 < S < 1.5 \\ \textit{Neutre} & -0.5 \leq S < 0.5 \\ \pm\,\textit{Ennemi} & \textit{si } -1.5 < S < -0.5 \\ \textit{Ennemi} & \textit{si } S \leq -1.5 \end{cases}$$

Modulation linguistique

Application des règles « du fichier **extraction_rules.py** ».

Négation

Inversion du score (par exemple, « pas un ami »).

Modalité

Atténuation ×0,5 (par exemple, «pourrait attaquer »).

Intensifiers

Augmentation ×1,5 (par exemple, « haine profonde »).

Limites actuelles

Ambiguïtés Patronymiques

Ex: Personnages partageant un même nom

Absence de Coréférence

Pronoms (il, elle) non résolus

Corpus → **NER / Alias** → **SVO Extraction** → **Polarité** → **Graphe**

Relations Implicites

Relations complexes vs. Hiérarchie simple

Seuils de polarité fixe

Pas de prise en compte des variations narratives entre chapitres

Dépendance Cooccurrence

Risque de perte d'interactions isolées

La langue naturelle est floue !

Mapping Tokens fragile

Détection limitée des dialogues

Dépendance Gold Standard

Expériences à venir

ID	Objectif	Métriques / hyperparamètres
Exp A	Analyser l'impact de la taille de la fenêtre de co-occurrence.	WINDOW_SIZE
Exp B	Analyser l'impact de l'heuristique « Best Name Only »	Precision / Recall
Exp C	Annotation manuelle d'un sous-corpus.	Cohen's κ
Exp D	Coefficient sensitivity analysis	β, δ, ε tuning

Nous avons aussi prévu un ensemble de tests ciblant les éléments critiques du pipeline (voir Annexe : A du rapport d'avancement)

Feuille de route du projet

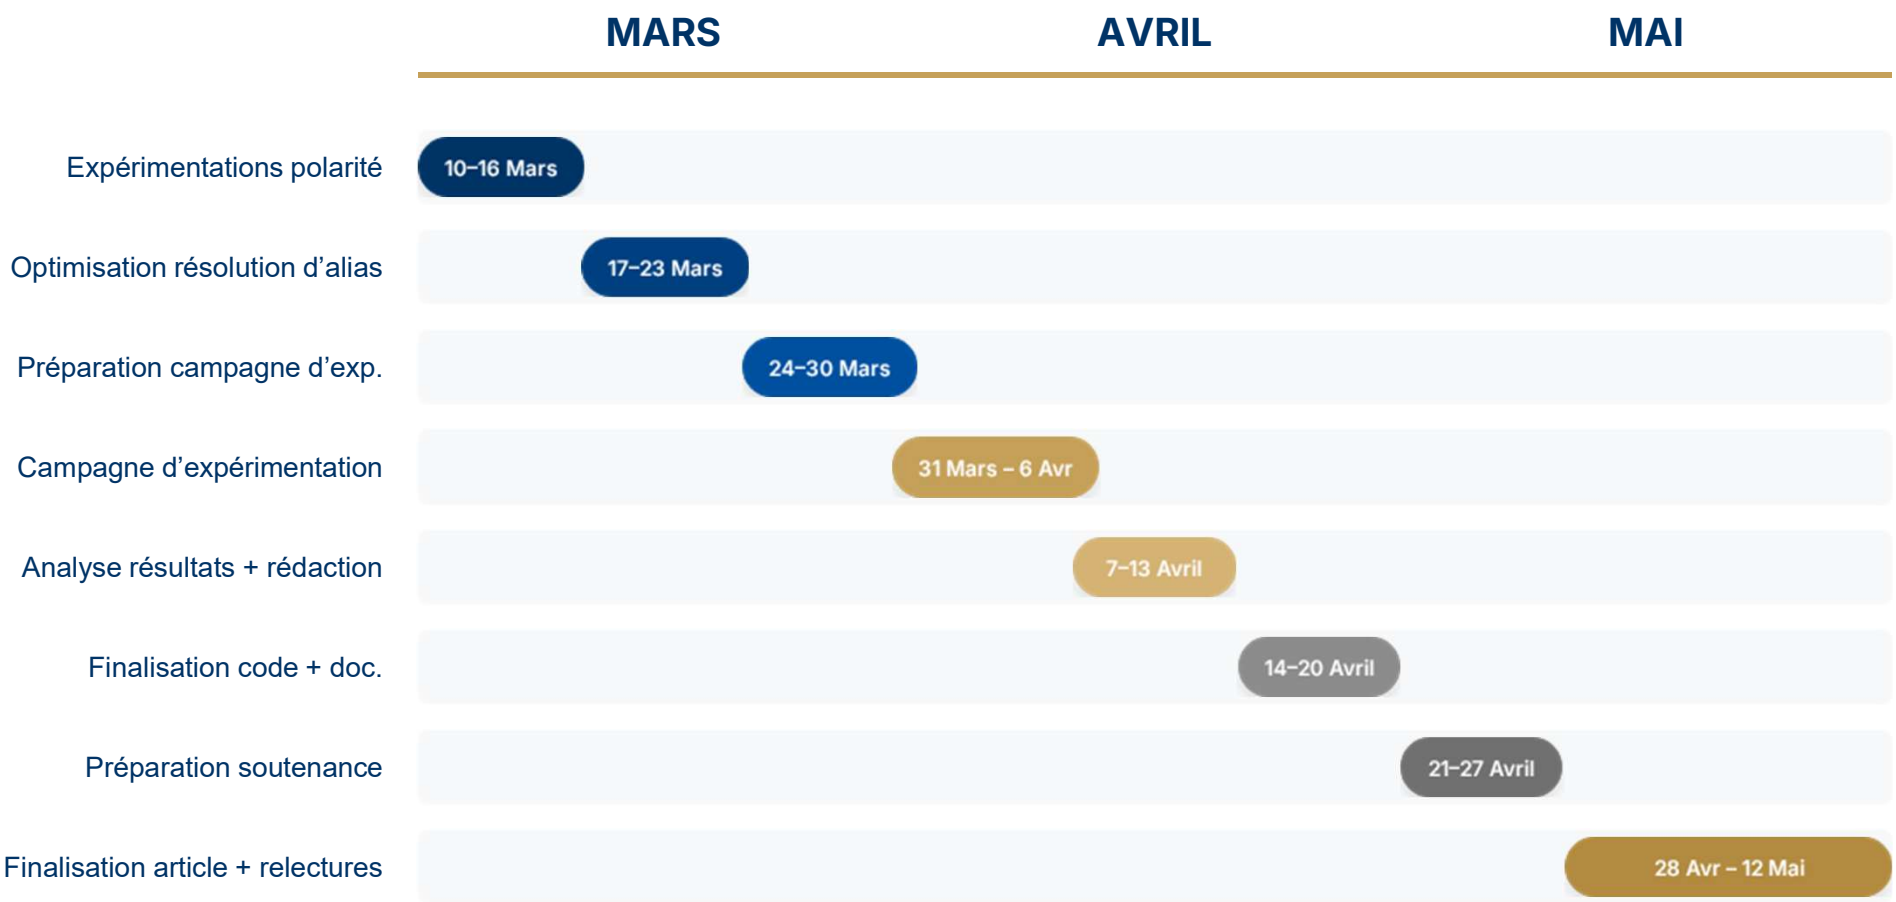

Conclusion

- Pipeline entièrement stabilisé
- Score F1 atteint 0,57
- Module de polarité intégré

Principale limitation

- Choix des hyperparamètres (seuils de discrétion, coefficients de polarité, etc.)
- Absence de graphes de références pour la polarité

Références Bibliographiques

Amalvy, A., Labatut, V., & Dufour, R. (2024). Apprendre à classer le contexte pour la reconnaissance d'entités nommées en utilisant un jeu de données synthétique. *CORIA.*

Bagga, A., & Baldwin, B. (1998). Entity-based cross-document coreferencing using the vector space model. *COLING-ACL.*

Clark, K., & Manning, C. D. (2016). Improving coreference resolution by learning entity-level distributed representations. *ACL.*

Elson, D. K., Dames, N., & McKeown, K. R. (2010). Extracting social networks from literary fiction. *ACL.*

Kuhlmann, M., & Oepen, S. (2016). Towards a catalogue of linguistic graph banks. *Computational Linguistics.*

Labatut, V., & Bost, X. (2019). Extraction and analysis of fictional character networks: A survey. *ACM Computing Surveys.*

Annexe A : Tendance centrale du réseau polarisé

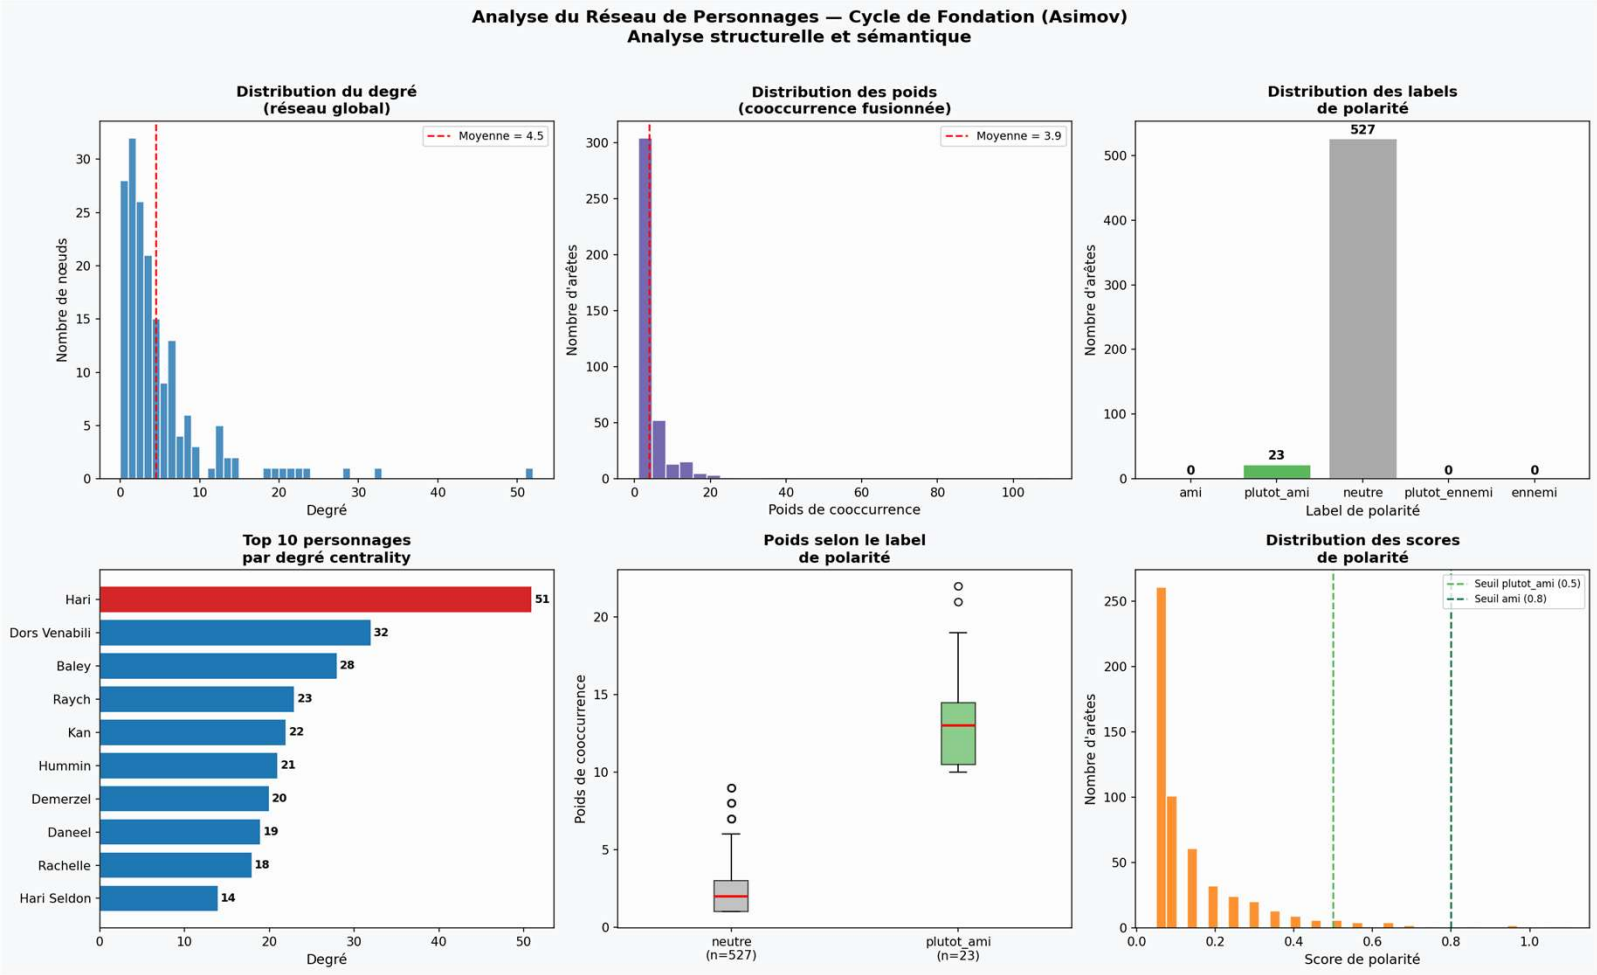

Annexe B : Personnages centraux (Top 9)

Rang	Personnage	Degré	Série principale
1	Hari (Seldon)	51	paf (Prélude à Fondation)
2	Dors Venabili	32	paf
3	Baley	28	lca (Les Cavernes d'acier)
4	Raych	23	paf
5	Kan	22	paf
6	Hummin	21	paf
7	Demerzel	20	paf
8	Daneel	19	lca / paf
9	Rachelle	18	paf

Annexe C : Déséquilibre structurel des labels

Label	Occurrences	Proportion	Valence	Seuil de discrétion
neutre	527	95,8 %	Neutre	$-0.5 \leq S < 0.5$
plutot_ami	23	4,2 %	Positive (faible)	$0.5 < S < 1.5$
ami	0	0,0 %	Positive (forte)	$S > 1.5$
plutot_ennemi	0	0,0 %	Négative (faible)	$-1.5 < S < -0.5$
ennemi	0	0,0 %	Négative (forte)	$S \leq -1.5$

Annexe D : Performances des modèles utilisés

Spacy (fr_core_news_md)			
Métrique	**Description**	**Score**	**Version**
POS_ACC	Étiquetage morpho-syntaxique (coarse-grained POS)	~96%	3.7

Reconnaissance NER (type = PER)			
Modèle	**Métrique**	**Description**	**Score**
Flair ner-french-large (v0.15.1)	F1-Score (PER)	F1-Score	~92% - 94%
spaCy fr_core_news_md (v3.7+)	F1-Score (PER)	F1-Score	~83% - 85%

Annexe B

Code

Rapport d’avancement

Questions?

Extraction Automatique de Réseaux de Personnages

Steve SANOGO & Malika GHILAS